

SDS-VLM MSA — API 인터페이스 명세

[아크릴 전달용 문서]

본 문서는 SDS-VLM 서비스를 Tango GenAI Platform(조나단)에 통합할 때 필요한 학습/배포/추론 전 과정의 API 스키마 및 연동 절차를 정의합니다.

1. 서비스 개요

항목	내용
서비스명	eva-vlm
버전	1.1.0
포트	8000
Ingress 경로	/msa/eva-vlm (플랫폼 담당자와 협의 후 확정)
베이스 이미지	nvidia/cuda:12.8.0-devel-ubuntu24.04

전체 엔드포인트 요약

엔드포인트	메서드	조나단 MSA 표준	설명
/health	GET	✅ 필수	서비스·모델 상태 확인
/info	GET	✅ 필수	서비스 메타정보
/run	POST	✅ 필수	추론 — 이미지+AIS → 텍스트
/jobs/{job_id}	GET	✅ 표준 (E2-A)	학습 진행 조회 — 플랫폼 표준 URL
/jobs/{job_id}/cancel	POST	✅ 표준 (E2-A)	학습 중지 — 플랫폼 표준 URL
/train	POST	확장	학습 시작 — 비동기, HTTP 202, job_id 반환
/train/status	GET	확장 (레거시)	학습 진행 조회 — 하위 호환 유지
/train/stop	POST	확장 (레거시)	학습 중지 — 하위 호환 유지
/models	GET	확장	체크포인트 목록
/deploy	POST	확장	배포(체크포인트 전환)

2. 인프라 사전 준비

NFS 볼륨 구조

플랫폼 NFS 스토리지에 아래 경로가 준비되어 있어야 합니다.

```
/nfs/eva/
├─ models/
│   └─ llm/
│       └─ Llama-3.1-8B-Instruct/  ← LLM 가중치 (~16GB)
```

```

|   ├── checkpoints/           ← 학습 결과 체크포인트 저장 위치
|   |   ├── sds_lora_ko_compact/ ← 예시 (projector.bin + LoRA)
|   |   └── ...
|   └── hf_cache/              ← (선택) CLIP 오프라인 캐시
└── data/
    ├── sds/                   ← SDS 학습 데이터셋
    │   └── 20260227/
    │       ├── 00001/
    │       │   ├── input_image.png
    │       │   ├── input_data.csv
    │       │   └── output_*.txt
    │       └── ...

```

필수 환경 변수

변수명	예시	설명
EVA_LLM_MODEL_PATH	/models/llm/Llama-3.1-8B-Instruct	LLM 경로 (필수)
EVA_CHECKPOINT_PATH	/models/checkpoints/sds_lora_ko_compact	초기 체크포인트 (필수)
EVA_CHECKPOINTS_ROOT	/models/checkpoints	체크포인트 탐색 루트
EVA_VISION_MODEL_NAME	openai/clip-vit-large-patch14-336	비전 인코더
EVA_DEVICE	cuda:0	추론 디바이스

3. 표준 엔드포인트

GET /health

Response

```
{
  "status": "healthy",
  "timestamp": "2026-05-12T10:00:00+00:00",
  "model_loaded": true,
  "device": "cuda:0",
  "vram_used_gb": 18.4
}
```

status 값: "healthy" | "loading" | "error"

모델 로드 시간~2분 → initialDelaySeconds: 120 이상 설정 필요

GET /info

Response

```
{
  "name": "eva-vlm",
  "version": "1.0.0",
}
```

```
"description": "...",
"capabilities": [
  "maritime-vlm-training",
  "checkpoint-management",
  "maritime-situation-description",
  "navigational-advice",
  "ais-image-fusion",
  "colreg-reasoning"
],
"vision_model": "openai/clip-vit-large-patch14-336",
"llm_model": "/models/llm/Llama-3.1-8B-Instruct",
"checkpoint": "/models/checkpoints/sds_lora_ko_compact",
"output_types": [
  "영문 해상상황요사",
  "한글 해상상황요사",
  "영문 항해조력메시지",
  "한글 항해조력메시지",
  "간결 항해조력메시지"
]
}
```

POST /run — 추론

Request

```
{
  "workspace_id": "ws-abc123",
  "project_id": "proj-def456",
  "params": {
    "image_base64": "<base64 PNG/JPG>",
    "ais_rows": [
      {
        "ship_id": 0, "my_ship": 1,
        "latitude": 34.45, "longitude": 127.73,
        "knot": 17.5, "heading": 141.0,
        "length": 93, "width": 28, "draft": 3
      },
      {
        "ship_id": 1, "my_ship": 0,
        "latitude": 34.44, "longitude": 127.73,
        "knot": 20.1, "heading": 115.0,
        "length": 134, "width": 24, "draft": 4,
        "bbox_x": 975, "bbox_y": 318, "bbox_width": 408, "bbox_height": 263
      }
    ],
    "output_type": "간결 항해조력메시지",
    "max_new_tokens": 512,
    "repetition_penalty": 1.1,
    "do_sample": false
  }
}
```

```
}  
}
```

output_type 선택지: "영문 해상상황묘사" | "한글 해상상황묘사" | "영문 항해조력메시지" | "한글 항해조력메시지" | "간결 항해조력메시지"

Response (성공)

```
{  
  "status": "success",  
  "result": {  
    "output_type": "간결 항해조력메시지",  
    "text": "우현 전방 타선(ID:1) 접근 중...",  
    "inference_time_sec": 12.3,  
    "active_checkpoint": "/models/checkpoints/sds_lora_ko_compact"  
  }  
}
```

4. 확장 엔드포인트 — 학습

POST /train — 학습 시작

SDS-VLM의 학습 파이프라인을 비동기로 실행합니다. 즉시 job_id 를 반환하고 백그라운드에서 학습을 진행합니다.

Request

```
{  
  "workspace_id": "ws-abc123",  
  "project_id": "proj-def456",  
  "params": {  
    "phase": "lora_sds",  
    "llm_model_path": "/models/llm/Llama-3.1-8B-Instruct",  
    "output_checkpoint_name": "sds_lora_ko_compact_v2",  
    "data_path": "/data/sds/sds_train_ko_compact.json",  
    "image_dir": "/data/sds/20260227",  
    "projector_path": "/models/checkpoints/clip_llama3l_lora_marine/projector.bin",  
    "resume_lora_path": "/models/checkpoints/clip_llama3l_lora_marine",  
    "sds_scenario": "ko_compact",  
    "num_epochs": 10,  
    "batch_size": 1,  
    "grad_accum": 2,  
    "learning_rate": 0.0002,  
    "zero_stage": 2  
  }  
}
```

params.phase 선택지

phase	학습 스크립트	주요 입력	설명
-------	---------	-------	----

projector	train.py	data_path, image_dir	Phase 1: 프로젝터 사전학습
lora	train.py	data_path, image_dir, projector_path	Phase 2: CC3M LoRA
lora_marine	train_text_lora.py	marine_data_path, resume_lora_path	Phase 3: 해양 텍스트 계속학습
lora_sds	train.py	data_path, image_dir, projector_path, resume_lora_path	Phase 4: SDS 특화 LoRA

Response (성공, HTTP 202 Accepted)

```
{
  "status": "success",
  "result": {
    "job_id": "a1b2c3d4",
    "message": "Phase 'lora_sds' 학습이 시작됐습니다. GET /jobs/a1b2c3d4 로 진행 상황을 확인하세요."
  }
}
```

GET /jobs/{job_id} — 학습 진행 조회 (표준 URL)

조나단 플랫폼 표준 URL입니다. 기존 /train/status?job_id= 와 동일한 응답을 반환합니다.

Response

```
{
  "job_id": "a1b2c3d4",
  "status": "running",
  "phase": "lora_sds",
  "progress_pct": 42.5,
  "current_step": 34,
  "total_steps": 80,
  "current_loss": 0.3821,
  "elapsed_sec": 387.2,
  "output_dir": "/models/checkpoints/sds_lora_ko_compact_v2",
  "error": null
}
```

status 값: "pending" | "running" | "completed" | "failed" | "stopped"

POST /jobs/{job_id}/cancel — 학습 중지 (표준 URL)

조나단 플랫폼 표준 URL입니다. 기존 /train/stop?job_id= 와 동일하게 동작합니다.

Response

```
{
  "status": "success",
}
```

```
{
  "job_id": "a1b2c3d4",
  "message": "학습 작업이 중지됐습니다."
}
```

GET /train/status?job_id={job_id} — 학습 진행 조회 (레거시)

하위 호환 유지용. 신규 연동은 `GET /jobs/{job_id}` 사용 권장.

Response

```
{
  "job_id": "a1b2c3d4",
  "status": "running",
  "phase": "lora_sds",
  "progress_pct": 42.5,
  "current_step": 34,
  "total_steps": 80,
  "current_loss": 0.3821,
  "elapsed_sec": 387.2,
  "output_dir": "/models/checkpoints/sds_lora_ko_compact_v2",
  "error": null
}
```

status 값: "pending" | "running" | "completed" | "failed" | "stopped"

POST /train/stop?job_id={job_id} — 학습 중지 (레거시)

하위 호환 유지용. 신규 연동은 `POST /jobs/{job_id}/cancel` 사용 권장.

Response

```
{
  "status": "success",
  "job_id": "a1b2c3d4",
  "message": "학습 작업이 중지됐습니다."
}
```

5. 확장 엔드포인트 — 배포

GET /models — 체크포인트 목록

NFS 체크포인트 루트를 스캔하여 `projector.bin` 이 있는 유효한 체크포인트 목록을 반환합니다.

Response

```
{
  "checkpoints_root": "/models/checkpoints",
  "active_checkpoint": "/models/checkpoints/sds_lora_ko_compact",
  "checkpoints": [
    {
```

```
    "name": "clip_llama31_lora",
    "path": "/models/checkpoints/clip_llama31_lora",
    "has_lora": true,
    "size_mb": 432.1,
    "created_at": "2026-04-15T08:30:00+00:00",
    "is_active": false
  },
  {
    "name": "sds_lora_ko_compact",
    "path": "/models/checkpoints/sds_lora_ko_compact",
    "has_lora": true,
    "size_mb": 438.7,
    "created_at": "2026-05-01T14:20:00+00:00",
    "is_active": true
  }
]
```

POST /deploy — 체크포인트 전환(배포)

학습 완료된 체크포인트를 추론 엔진에 로드합니다. 기존 모델을 GPU에서 해제하고 새 체크포인트를 적재합니다.

주의: 로드 시간 ~2분 소요. 로드 중 /run 추론은 `SERVICE_UNAVAILABLE` 응답.

Request

```
{
  "workspace_id": "ws-abc123",
  "project_id": "proj-def456",
  "params": {
    "checkpoint_name": "sds_lora_ko_compact_v2"
  }
}
```

Response (성공)

```
{
  "status": "success",
  "checkpoint_path": "/models/checkpoints/sds_lora_ko_compact_v2",
  "device": "cuda:0",
  "vram_used_gb": 18.6,
  "message": "체크포인트 'sds_lora_ko_compact_v2' 로드 완료."
}
```

6. 에러 코드

코드	HTTP	설명
INVALID_PARAMS	400	필수 필드 누락 또는 형식 오류

NOT_FOUND	404	지정한 체크포인트/job_id 없음
RESOURCE_EXHAUSTED	429	이미 학습 중 (GPU 1장 환경 제약)
SERVICE_UNAVAILABLE	503	모델 로드 미완료 또는 전환 중
INTERNAL_ERROR	500	내부 오류

7. 조나단 UI 연동을 위한 아크릴 작업 범위

SDS-VLM의 학습/배포/추론을 조나단 대시보드에서 직접 제어하려면 아크릴 측 UI 작업이 필요합니다.

조나단 UI 화면	에바 연동 내용	호출 API
학습 프로젝트	SDS-VLM 학습 시작/중지/진행률 표시	POST /train, GET /jobs/{job_id}, POST /jobs/{job_id}/cancel
모델 관리	체크포인트 목록 및 현재 활성 모델 표시	GET /models
배포	체크포인트 선택 후 서비스 적용	POST /deploy
플래그그래운드	이미지+AIS 입력 → 추론 결과	POST /run

8. Helm Chart 설치 명령

```
helm install eva-vlm-1 ./helm_chart/ \
  -n tango-eva --create-namespace \
  --set metadata.namespace=tango-eva \
  --set metadata.workspace_id=<워크스페이스_ID> \
  --set metadata.project_id=<프로젝트_ID> \
  --set metadata.pod_name=eva-vlm-1 \
  --set labels.helm_name=eva-vlm-1 \
  --set backend.image=yvyee/eva-vlm-backend:1.1.0 \
  --set "backend.env.EVA_LLM_MODEL_PATH=/models/llm/Llama-3.1-8B-Instruct" \
  --set "backend.env.EVA_CHECKPOINT_PATH=/models/checkpoints/sds_lora_ko_compact" \
  --set "backend.env.EVA_CHECKPOINTS_ROOT=/models/checkpoints" \
  --set backend.volumes[0].nfs.server=<NFS_SERVER_IP> \
  --set backend.volumes[0].nfs.path=/nfs/eva/models \
  --set ingress.enabled=true
```