# 해양 자율항해 VLM 개발을 위한

# Tango2 GenAI Platform 활용 가이드

**Tango2 GenAI Platform Usage Guide for Maritime Autonomous Navigation VLM**

| 작 성 | 검 토 | 승 인 |
|---|---|---|
| - | - | - |
| (인) | (인) | (인) |

| 번호 | 일자 | 사유 |
|---|---|---|
| 1 | 2026.04.14 | 최초 작성 |
| | | |
| | | |
| | | |

# 목 차

**1. 개요**
1.1 작성 목적 및 배경
1.2 대상 독자
1.3 Tango2 플랫폼 소개
1.4 아키텍처 요약
1.5 문서 구성 안내
**2. 사전 준비**
2.1 계정 생성 및 로그인
2.2 워크스페이스 확인
2.3 자원 할당 확인
**3. 데이터셋 구축**
3.1 데이터셋 카드 생성
3.2 데이터 업로드
3.3 데이터 검증
3.4 데이터셋 증분 관리
**4. 모델 생성 및 파인튜닝**
4.1 모델 카드 생성
4.2 학습 데이터 연결
4.3 파인튜닝 파라미터 설정
4.4 학습 모니터링 및 커밋
**5. 플레이그라운드 추론 테스트**
5.1 플레이그라운드 카드 생성
5.2 추론 모델 불러오기
5.3 모델 배포
5.4 테스트 수행
5.4.1 실시간 질의 입력
5.4.2 사전 데이터셋 배치 테스트
5.5 배포 모니터링
5.6 테스트 기록 및 시스템 로그
**6. 평가 및 반복 개선**
6.1 COLREG 전문가 평가
6.2 오류 패턴 분석 및 재학습
**7. 에이전트 고도화 시나리오**
**부록 A. 용어집 (Glossary)**
**부록 B. 자주 묻는 질문 (FAQ)**

# 1. 개요

## 1.1 작성 목적 및 배경

본 문서는 과학기술정보통신부·IITP 지원「SDx 지능형 서비스의 최적 실행을 위한 생성형AI 지원 시스템SW 프레임워크 기술개발」과제(2025.07 ~ 2028.12)의 해양 자율항해 세부 시나리오(SDS, Ship Detection & Situation)를 수행하기 위해 작성되었다. ETRI 주관, (주)아크릴·고려대·에이브노틱스·슈어데이터 등 산·학·연 8개 기관이 참여하며, 오픈소스 GenAI 프레임워크인 TANGO(GitHub: ML-TANGO/TANGO) 기반 Tango2 GenAI Platform을 공통 개발·학습·배포 인프라로 활용한다.

SDS 시나리오는 선박 카메라 영상과 AIS 센서 데이터를 입력으로 VLM(Vision Language Model)을 파인튜닝하여, ① 해상상황묘사(주변 선박 위치·움직임을 자연어로 서술)와 ② 항해조력(방향·속도 지시)을 생성하고, COLREG(국제해상충돌예방규칙) 전문가 평가에서 오류율 15% 이하를 달성하는 것을 1차년도 정량 목표로 한다.

본 문서는 위 목표를 달성하기 위해 Tango2 플랫폼에서 데이터셋을 구축하고, VLM을 파인튜닝·배포·평가하는 전체 절차를 안내한다. 업무회의(2026.02.06)에서 정의한 자율항해용 의사결정 및 항해조력 아키텍처를 기반으로, 각 개발 단계에서 플랫폼의 어떤 기능을 어떤 순서로 사용해야 하는지를 구체적으로 기술한다.

## 1.2 대상 독자

- 해양 VLM 파인튜닝 및 평가를 수행하는 AI 연구자
- 데이터셋 구축 및 라벨링 담당자
- Tango2 플랫폼 워크스페이스 관리자
- Tango2 플랫폼을 처음 접하는 외부 참여 기관 담당자

## 1.3 Tango2 플랫폼 소개

Tango2 GenAI Platform은 (주)아크릴이 개발한 오픈소스 GenAI 프레임워크 TANGO의 2세대 플랫폼으로, AI 모델의 데이터 관리·학습·배포·운영 전주기를 단일 웹 환경에서 수행할 수 있도록 설계되었다. 주요 특장점은 다음과 같다.

- GPU 자원 가상화 및 워크스페이스 기반 관리: 사용자·프로젝트별 독립 워크스페이스에서 GPU 인스턴스를 할당·관리하며, 자원 요청-할당-펜딩 프로세스를 통해 다중 사용자 환경에서도 효율적으로 자원을 운영한다.
- 데이터셋-모델-배포 통합 관리: 데이터셋 업로드·버전 관리, HuggingFace 모델 검색·파인튜닝, 플레이그라운드 기반 추론 테스트·배포를 하나의 플랫폼에서 연속적으로 수행한다.
- PEFT(LoRA/DoRA) 기반 효율적 파인튜닝: 전체 파라미터를 동결한 채 소규모 어댑터만 학습하는 방식을 지원하여, 제한된 GPU 자원에서도 대규모 VLM 의 파인튜닝이 가능하다.
- RESTful API 기반 모델 서빙: 배포된 모델을 외부 시스템(Prompt Generator, TTS 모듈 등)과 API 로 연동하여 실시간 추론 서비스를 구성할 수 있다.
- 배포 모니터링 및 테스트 기록: 배포 상태·성능 지표를 실시간 모니터링하고, 테스트 이력과 시스템 로그를 체계적으로 관리한다.

## 1.4 아키텍처 요약

본 프로젝트의 전체 파이프라인은 아래와 같다.

| 단계 | 구성 요소 | 설명 |
|---|---|---|
| 입력 | 정면 카메라 영상 + AIS 센서데이터 | 선박 전방 카메라 이미지와 위경도, 속력, 침로 등 AIS 정보 |
| 전처리 | Prompt Generator | 이미지와 AIS 데이터를 결합하여 VLM 입력용 구조화 프롬프트 생성 |
| 모델 | Vision Language Model (128k) | 멀티모달 입력을 처리하는 대규모 비전-언어 모델 |
| 출력 | 항해조력 + 해상상황묘사 | {좌현/정면/우현} + {감속/정속/가속} 지시 및 상황 서술 텍스트 |
| 평가 | COLREG 전문가 평가 | 국제해상충돌예방규칙 기반, 전문가에 의한 오류율 15% 이하 목표 |

## 1.5 문서 구성 안내

본 문서는 Tango2 플랫폼을 활용한 해양 VLM 개발의 전 과정을 단계별로 안내한다. 독자의 역할에 따라 아래 읽기 경로를 참고하여 필요한 장부터 확인할 수 있다.

| **독자 역할** | **주요 관심 장** | **설명** |
|---|---|---|
| AI 연구자<br>(파인튜닝 담당) | 3장 → 4장 → 5장 → 6장 | 데이터 준비부터 학습, 테스트, 평가까지 순차 진행 |
| 데이터셋 구축 담당자 | 2장 → 3장 | 플랫폼 접속 후 데이터셋 생성 및 업로드에 집중 |
| 플랫폼 관리자 | 2장 → 7장 | 워크스페이스 설정, 자원 할당, 에이전트 고도화 방향 확인 |
| 프로젝트 총괄 | 1장 → 6장 → 7장 | 전체 아키텍처와 평가 기준, 고도화 방향 파악 |

# 2. 사전 준비

## 2.1 계정 생성 및 로그인

Tango2 GenAI Platform은 오픈소스로 공개된 설치형 플랫폼으로, 사용자가 자체 인프라에 설치한 후 사용하거나 주관기관이 지정한 공용 개발 인프라에 설치된 환경을 통해 사용한다. 플랫폼 접속 절차는 다음과 같다.

① 워크스페이스 관리자에게 접속 URL을 확인한다 (URL은 설치 환경에 따라 상이).

② 웹 브라우저에서 해당 URL로 접속하여 계정으로 로그인한다.

③ 계정이 없는 경우, 로그인 화면의 "회원가입" 버튼으로 가입을 신청한 후 관리자 승인을 대기한다.

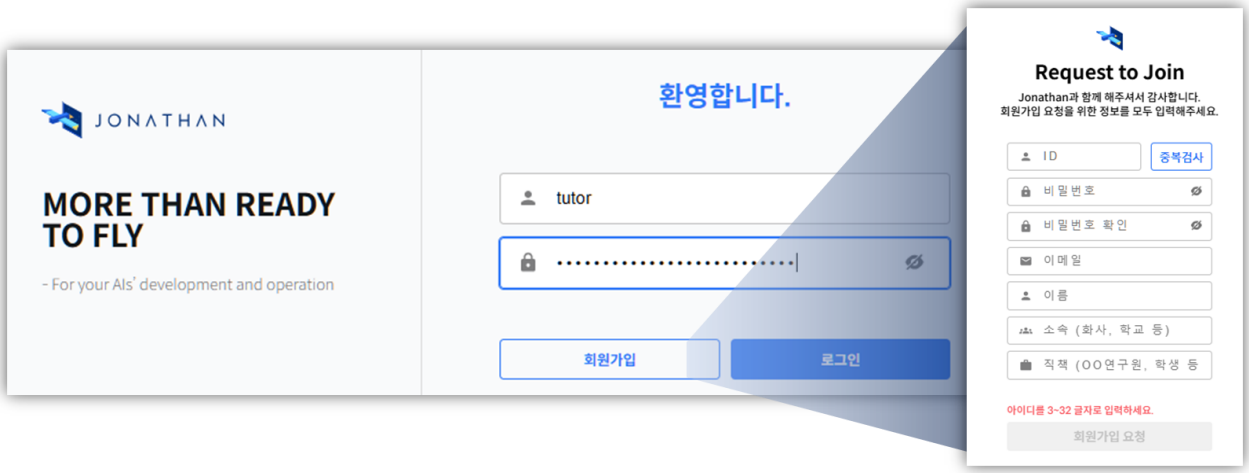


*[그림 2-1] 로그인 화면*

> **참고: 로그인 후 대시보드에서 소속 워크스페이스 목록 및** 각 워크스페이스의 자원 사용 현황을 확인할 수 있다.

## 2.2 워크스페이스 확인

해양 VLM 프로젝트 전용 워크스페이스에 배정되어 있는지 확인한다. 워크스페이스란 프로젝트 단위로 구성원, GPU 인스턴스, 스토리지 등의 자원을 묶어 관리하는 논리적 작업 공간이다. 각 워크스페이스에는 GPU 인스턴스와 스토리지(Main: 모델·시스템 파일 저장, Data: 학습 데이터 저장)가 할당되어 있으며, 워크스페이스 관리자가 자원 배분을 관리한다.

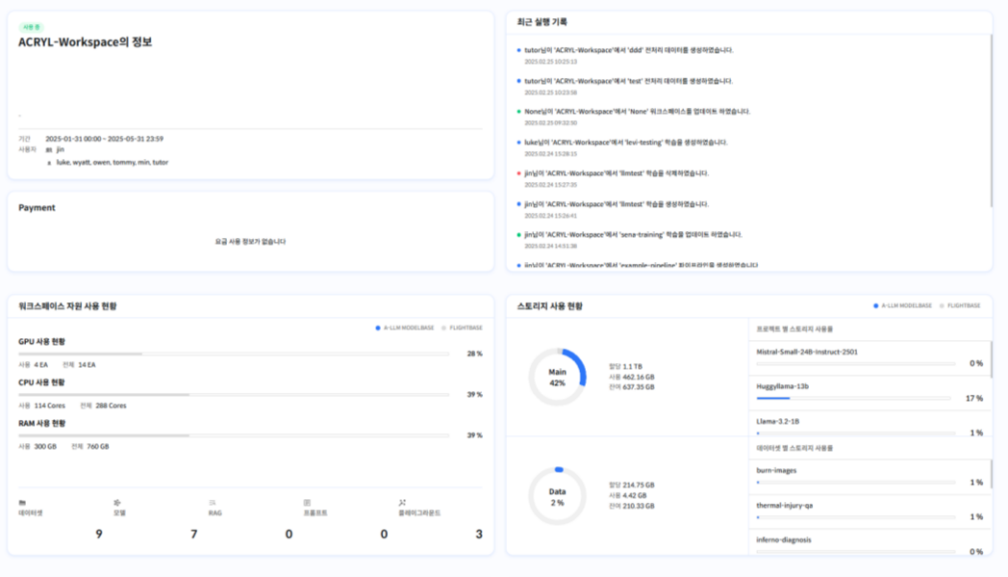


*[그림 2-2a] 대시보드 화면 (상단)*

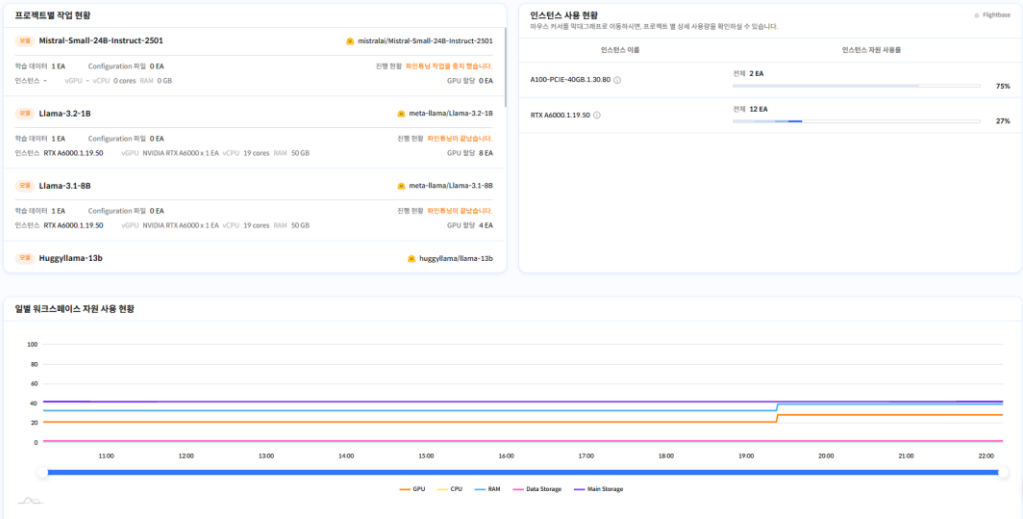


*[그림 2-2b] 대시보드 화면 (하단)*

대시보드에서 확인할 수 있는 정보:

- 워크스페이스 이름, 사용자 목록, 관리자 정보
- 할당된 인스턴스(GPU) 현황 및 저장소 사용량
- 최근 실행 기록 (학습, 배포 등)
- 프로젝트별 작업 현황

## 2.3 자원 할당 확인

VLM 파인튜닝은 대규모 GPU 자원이 필요하므로(참고: 128k VLM 기준 최소 A100 80GB × 4장 이상 권장), 워크스페이스에 충분한 인스턴스가 할당되어 있는지 확인한다. 부족한 경우 워크스페이스 관리자가 워크스페이스 수정 요청을 통해 인스턴스 추가를 요청할 수 있다. 인스턴스 할당은 플랫폼 관리자의 승인 하에 수정된다.

# 3. 데이터셋 구축

## 3.1 데이터셋 카드 생성

좌측 메뉴에서 "데이터셋"을 클릭하고, "데이터셋 생성" 버튼을 눌러 새로운 데이터셋 카드를 생성한다. 데이터셋 카드란 학습에 사용할 데이터 파일들을 하나의 단위로 묶어 관리하는 메타데이터 컨테이너이다. 즉, 데이터셋 카드는 데이터 파일 자체가 아니라 파일들을 담는 '폴더' 역할이며, 카드를 먼저 생성한 후 그 안에 데이터를 업로드하는 구조이다. 이후 모델 학습 시 이 카드를 선택하여 데이터를 연결한다.

- 이름 예시: `maritime-sds-v1`
- 접근 권한: **"읽기&쓰기"**로 설정(팀원의 학습 및 배포 과정에서 데이터 수정이 가능하도록 권장)

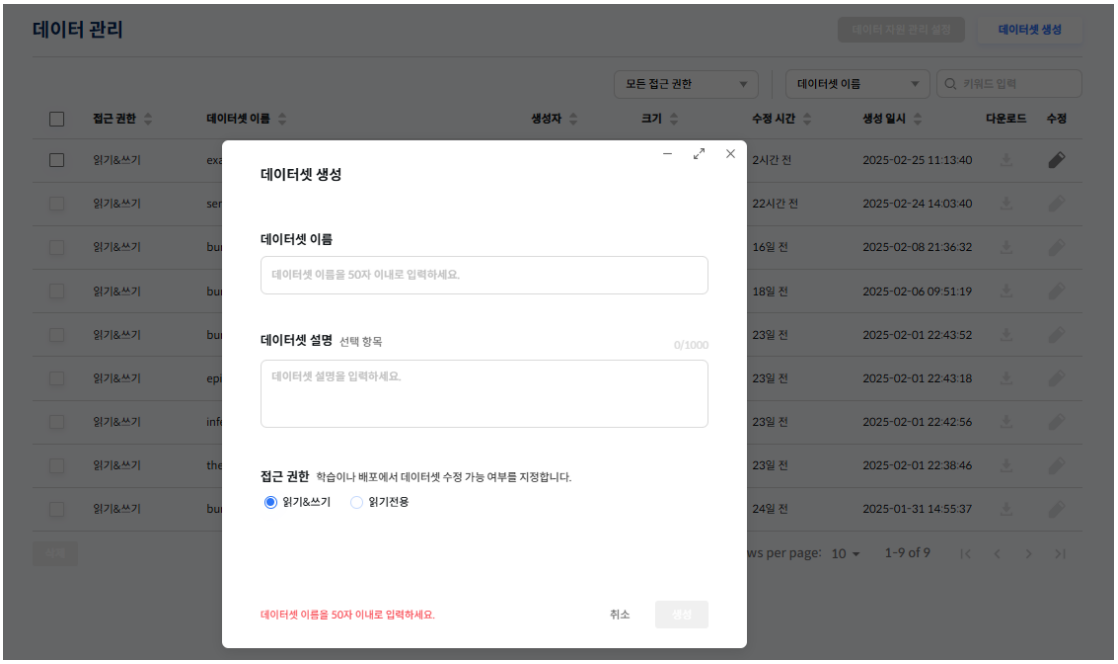


*[그림 3-1] 데이터셋 생성 화면*

## 3.2 데이터 업로드

생성한 데이터셋 이름을 클릭하여 상세 화면으로 이동한 뒤, "데이터 업로드" 버튼을 눌러 아래 폴더 구조에 맞추어 파일을 업로드한다. 업로드 시 폴더 단위 일괄 업로드가 가능하며, 단일 파일 용량 제한 및 동시 업로드 수에 유의한다(상세 제한 사항은 플랫폼 관리자에게 확인).

| 폴더 | 파일 형식 | 내용 |
|---|---|---|
| images/ | JPG / PNG | 정면 카메라 영상 프레임 |
| ais_data/ | CSV | AIS 센서 데이터 (위경도, 속력, 침로, 선수방위 등) |
| labels/ | JSON | 항해조력 라벨({좌현/정면/우현}, {감속/정속/가속}) + 해상상황묘사 텍스트 |

*[그림 3-2] 데이터 업로드 화면*

> ※ 라벨링 작업을 위한 기능 추가 예정. 라벨링 완료 후 결과물(JSON)을 Tango 데이터셋에 업로드하여 학습에 활용한다.

**라벨 JSON 형식 예시**

labels/ 폴더 내 각 JSON 파일은 하나의 카메라 프레임에 대한 항해조력 라벨과 해상상황묘사를 포함하며, 아래와 같은 형식으로 작성한다.

```
{
  "image_id": "frame_20260215_143022",
  "image_file": "images/frame_20260215_143022.jpg",
  "ais_file": "ais_data/frame_20260215_143022.csv",
  "navigation_aid": {
    "direction": "좌현",
    "speed": "감속"
  },
  "situation_description": "본선 정선 상태. 좌현 약 0.5해리에 유람선이 횡단 중이며, COLREG Rule 15에 따라 좌현 회피 및 감속이 요구됨.",
  "colreg_rules": ["Rule 15", "Rule 16"],
  "evaluator": "expert_01",
  "timestamp": "2026-02-15T14:30:22Z"
}
```

**주요 필드 설명:**

- navigation_aid: 항해조력 지시. direction 은 {좌현, 정면, 우현}, speed 는 {감속, 정속, 가속} 중 택 1
- situation_description: 해상상황묘사 텍스트. 주변 선박 상황과 적용 COLREG Rule 을 자연어로 기술
- colreg_rules: 해당 상황에 적용되는 COLREG 규칙 목록
- image_file / ais_file: 대응하는 카메라 영상 및 AIS 데이터 파일 경로

## 3.3 데이터 검증

업로드 후 파일 브라우저 기능을 활성화하여 데이터를 검수한다.

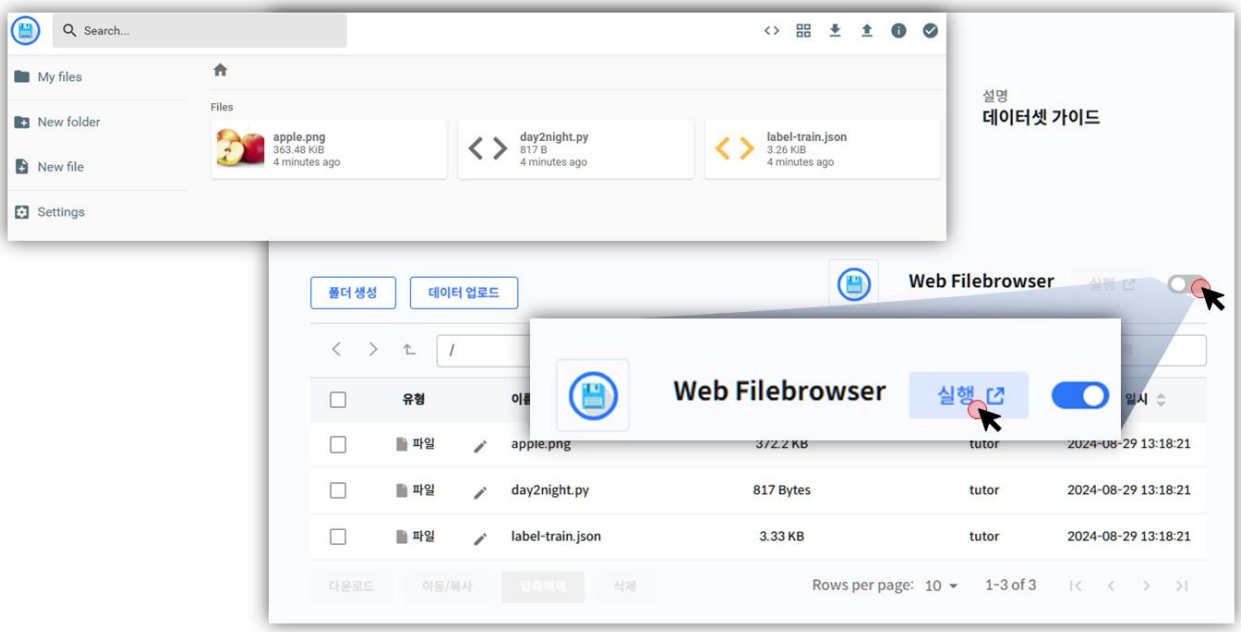


*[그림 3-3] 데이터 검증 화면*

- 이미지 파일 클릭 시 미리보기로 카메라 영상이 정상인지 육안 확인
- 폴더 구조 탐색으로 이미지-AIS-라벨 파일 간 대응 관계 확인
- 데이터셋 상세 조회 화면에서 전체 파일 수, 용량 등 현황 확인

> **참고: Filebrowser 기능을 활성화하면 상세 파일 탐색이 가능하다. 해당 기능은 세션 종료 시까지 데이터셋 내에서** 유지된다.

## 3.4 데이터셋 증분 관리

프로젝트 일정에 따라 데이터셋은 단계적으로 확장한다.

| 시기 | 작업 | 규모 |
|---|---|---|
| 2월 말 | 데이터셋 샘플 업로드 및 검증 | 100개 |
| 3~5월 | COLREG 위반 사례 반영 데이터 추가 생성, 전문가 온라인 레이블링 | 지속 확장 |
| 6월 말 | 전체 데이터셋 완성 | 10K |

# 4. 모델 생성 및 파인튜닝

## 4.1 모델 카드 생성

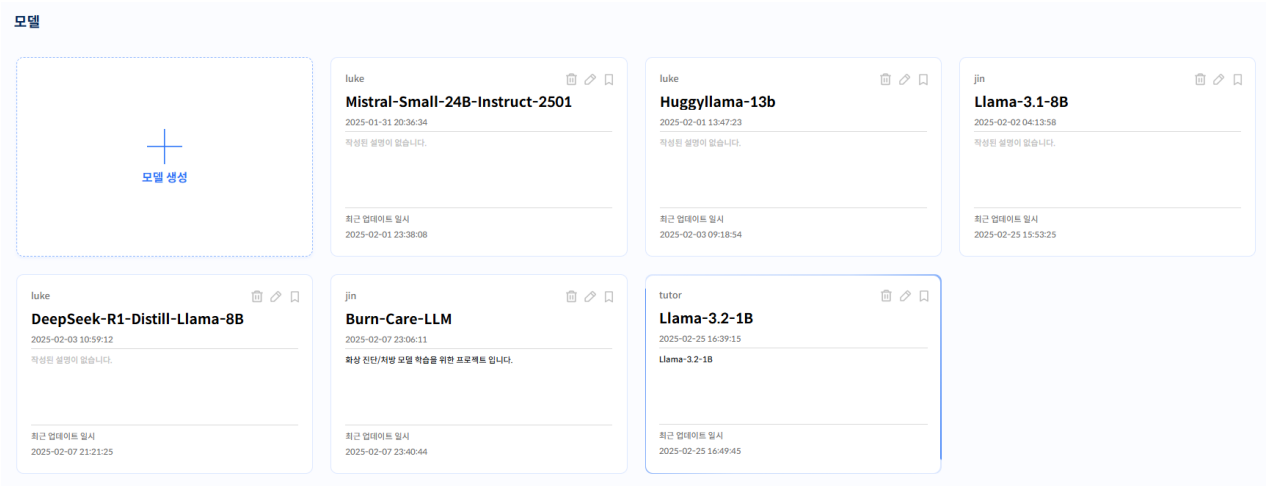


*[그림 4-1] 모델 카드 생성 화면*

좌측 메뉴에서 "모델"을 클릭하고, "새 모델 카드 생성" 버튼을 눌러 VLM 베이스 모델을 불러온다. 모델 카드는 3장의 데이터셋 카드와 마찬가지로, 모델의 설정·학습 이력·체크포인트 등을 하나로 묶어 관리하는 단위이다.

- **모델 유형 선택:** "HuggingFace 검색"을 선택하여 128k 컨텍스트를 지원하는 VLM 을 검색한다 (예: LLaVA 계열, Qwen-VL 등).
- **접근 권한:** 팀원과 공유가 필요한 경우 적절한 접근 권한을 설정한다.

> **참고: HuggingFace 모델을 선택하면 모델 상세 링크가 표시되며**, 학습에 필요한 데이터 형식 등을 확인할 수 있다.

## 4.2 학습 데이터 연결

모델 카드 상세 화면 하단의 "파인튜닝" 탭으로 이동한 뒤, "학습 데이터 업로드" 버튼을 눌러 3장에서 생성한 데이터셋 카드(maritime-sds-v1)를 선택한다. 이 버튼은 새 데이터를 업로드하는 것이 아니라 기존 데이터셋 카드를 모델에 연결하는 기능이다. 사전에 만든 데이터셋 카드 목록에서 선택할 수 있으며, 해당 데이터셋의 파일 구조를 확인할 수 있다.

*[그림 4-2] 학습 데이터 연결 화면*

## 4.3 파인튜닝 파라미터 설정

파인튜닝 파라미터를 수치 입력 또는 슬라이더 UI를 통해 조정한다. 주요 설정 항목:

| 파라미터 | 설명 | 권장 참고사항 |
|---|---|---|
| Epoch | 전체 데이터를 몇 회 반복 학습할지 설정 | 데이터 규모에 따라 조정 (샘플 100개일 때 vs 10K일 때 상이) |
| Batch Size | 한 번에 처리하는 데이터 수 | GPU 메모리에 맞춰 설정 |
| Learning Rate | 학습률 | VLM 파인튜닝 시 낮은 값으로 시작 권장 |
| LoRA/DoRA | PEFT 파인튜닝 방식 | 전체 파라미터 동결 후 어댑터만 학습하여 GPU 자원 절약 |

모든 파라미터 설정이 완료되면 "실행" 버튼을 클릭하여 학습을 시작한다. 학습 진행 상황은 4.4절의 모니터링 화면에서 확인할 수 있다.

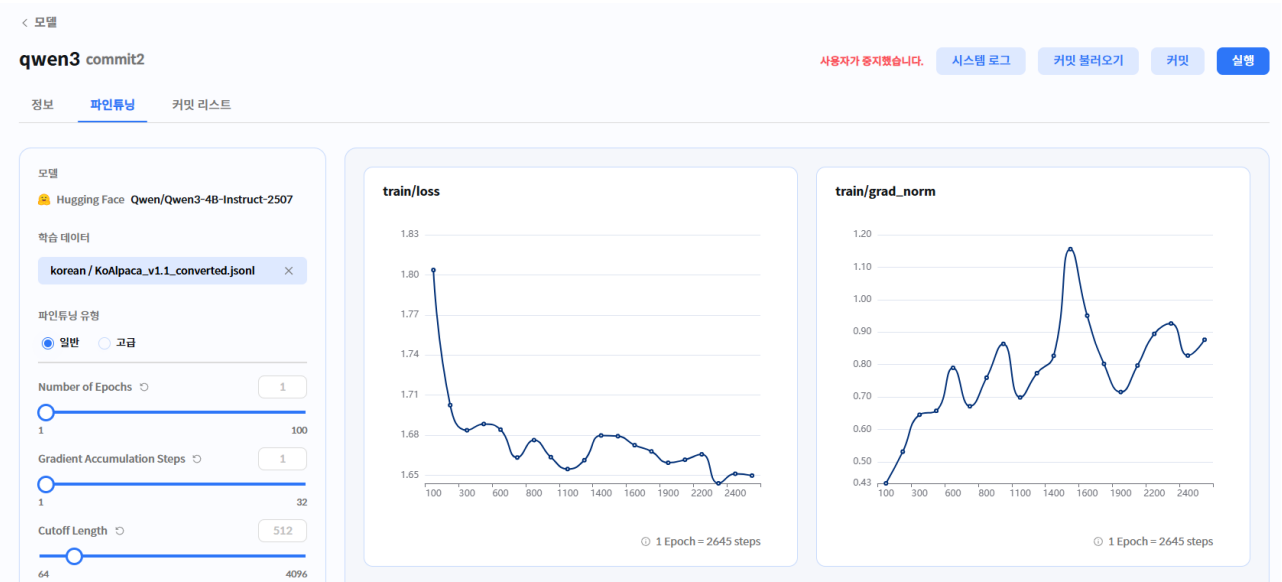


*[그림 4-3a] 파인튜닝 파라미터 설정 (상단)*

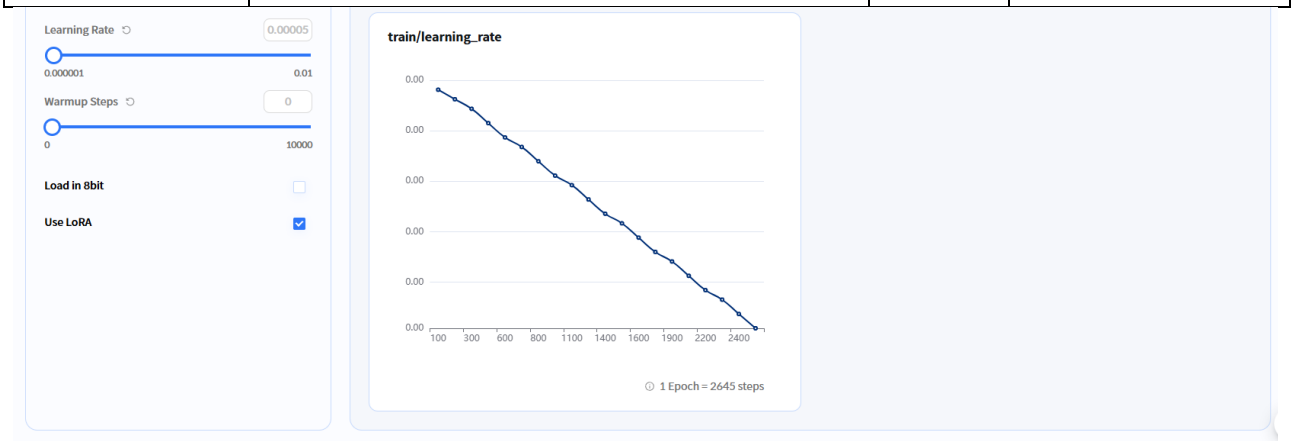


*[그림 4-3b] 파인튜닝 파라미터 설정 (하단)*

## 4.4 학습 모니터링 및 커밋

파인튜닝 진행 중에는 다음을 실시간으로 확인할 수 있다.

- **학습결과 그래프:** Loss, Learning Rate 등의 지표를 실시간 시각화
- **시스템 로그:** "자원 할당 중", "파인튜닝 진행 중" 등 현재 상태 메시지
- **상태 표시:** 모델 카드 테두리 색상으로 파인튜닝 진행 여부 판단 가능

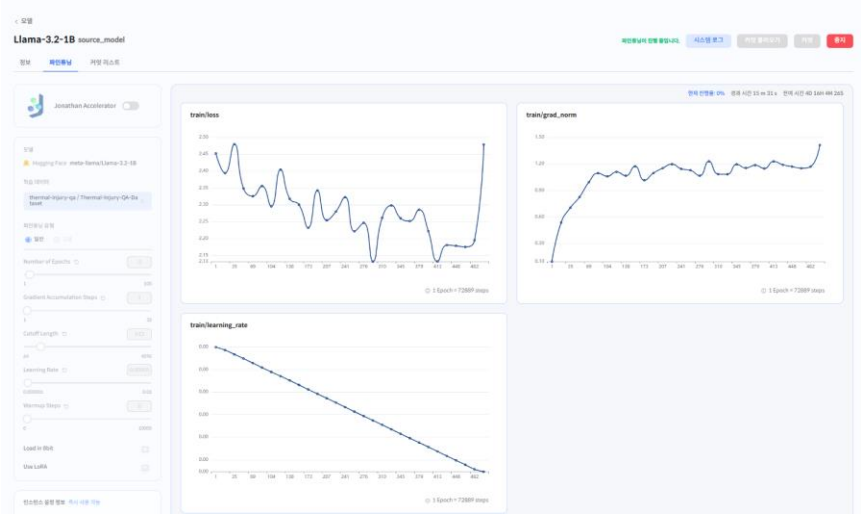


*[그림 4-4] 학습 모니터링 화면*

학습을 중간에 멈추거나 특정 시점의 상태를 저장하고자 할 때, 커밋 기능을 사용한다. 커밋이란 해당 시점의 모델 가중치와 학습 설정을 하나의 스냅샷으로 저장하는 기능으로, 소프트웨어 버전 관리의 '커밋'과 유사한 개념이다.

- 커밋 시 현재 파인튜닝 상태가 체크포인트로 저장된다.
- 커밋리스트에서 이전 커밋 이름을 클릭하면 해당 체크포인트로 돌아가 재학습할 수 있다.
- 카드 생성 시점의 상태는 source_model 로 기본 저장된다.

> **참고: 다양한 하이퍼파라미터 조합을 실험할 때마다 커밋을 생성하면, 최적 조건을 체계적으로** 추적할 수 있다.

# 5. 플레이그라운드 추론 테스트

## 5.1 플레이그라운드 카드 생성

4장에서 파인튜닝이 완료된 모델을 실제로 테스트하려면 플레이그라운드를 생성해야 한다. 좌측 메뉴에서 "플레이그라운드"를 클릭하고, "새 플레이그라운드 카드 생성" 버튼을 누른다. 이름과 설명을 입력하고, 접근 권한을 설정한다.

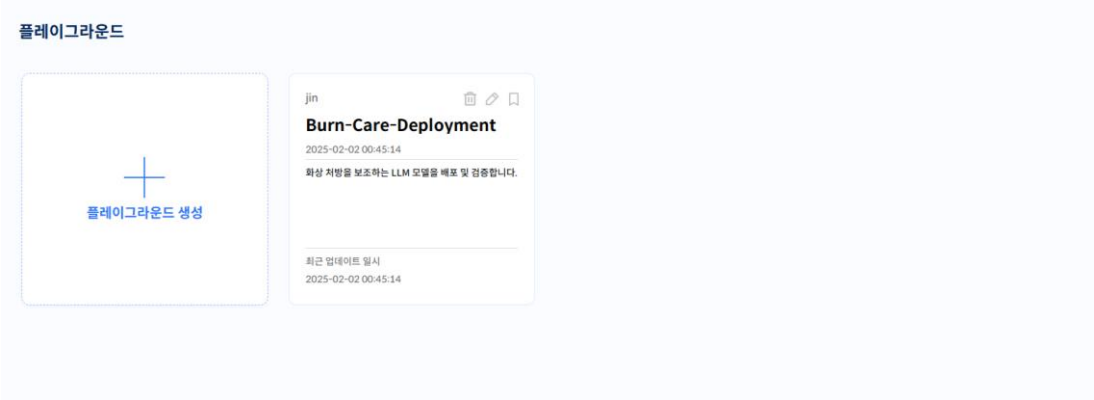


*[그림 5-1a] 플레이그라운드 카드 생성*

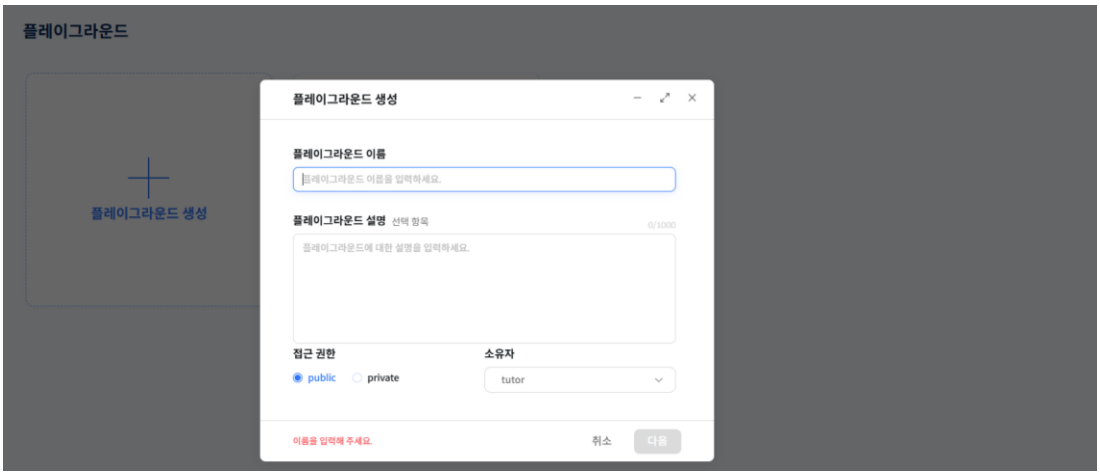


*[그림 5-1b] 플레이그라운드 화면*

## 5.2 추론 모델 불러오기

플레이그라운드 카드 정보 화면에서 "추론 모델 선택"을 클릭하여 파인튜닝한 모델을 불러온다.

- 사전에 생성한 모델 카드 목록에서 파인튜닝한 모델을 선택할 수 있다.
- 특정 커밋된 체크포인트를 선택하여 불러올 수 있다 (예: epoch 5 시점 vs epoch 10 시점 비교).
- HuggingFace 모델을 직접 검색하여 불러오는 것도 가능하다.

## 5.3 모델 배포

5.2에서 모델을 불러온 후, "배포" 버튼을 클릭하면 자원 할당이 시작되고 모델이 배포된다. 자원 상황에 따라 배포까지 수 분이 소요될 수 있으며, 진행 상태는 카드 상단의 상태 표시줄에서 확인할 수 있다. 배포가 완료되면 다음 정보를 확인할 수 있다.

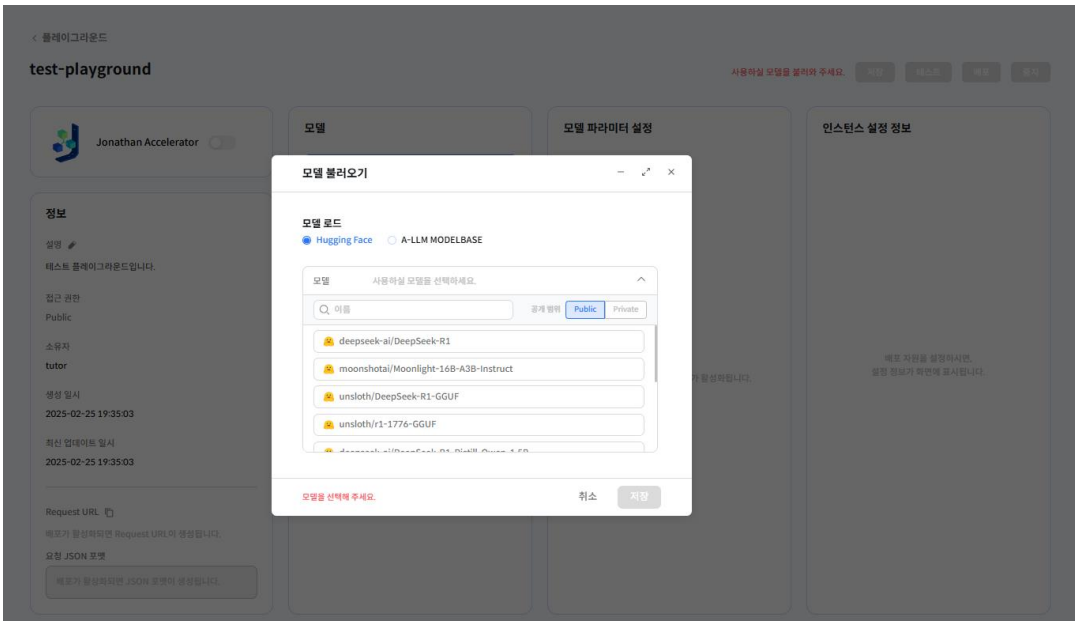


*[그림 5-2a] 모델 배포 화면 (배포 시작)*

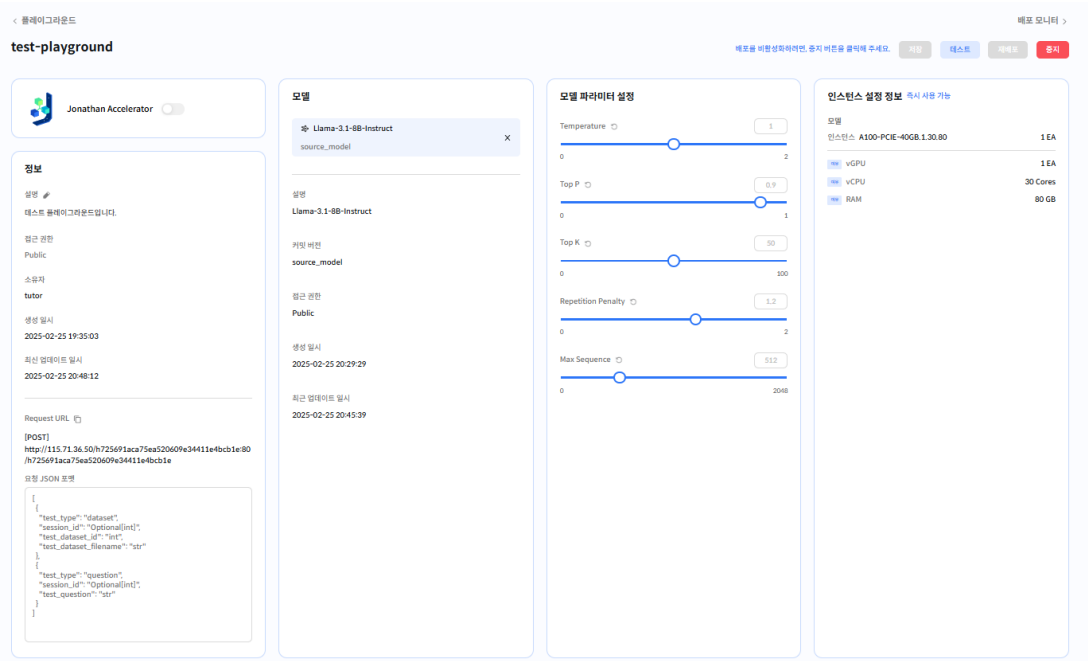


*[그림 5-2b] 모델 배포 화면 (배포 완료)*

- **API Request URL:** 외부 시스템(Prompt Generator 등)과 연동할 수 있는 API 엔드포인트
- **요청 JSON 포맷:** API 호출 시 사용할 요청 형식 확인
- **모델 파라미터:** 추론 모델 파라미터를 수치 입력 또는 슬라이더로 조정 가능

**API 연동 예시**

배포 완료 후 제공되는 API Request URL을 사용하여 외부 시스템(Prompt Generator 등)에서 모델을 호출할 수 있다. 아래는 Python requests 라이브러리를 이용한 호출 예시이다.

```
import requests

# 배포 완료 시 제공되는 API Request URL
API_URL = "http://<배포_URL>/api/v1/predict"

# 요청 데이터 구성
payload = {
    "image": "<base64_encoded_camera_image>",
    "ais_data": {
        "longitude": 126.978,
        "latitude": 37.566,
        "speed": 12.5,
        "course": 245.0,
        "heading": 243.0
    },
    "prompt": "본선 정선 상태에서 주변 선박 상황을 묘사하고 항해조력을 제시하라."
}

response = requests.post(API_URL, json=payload)
result = response.json()

# 응답 예시
# {
#   "navigation_aid": {"direction": "좌현", "speed": "감속"},
#   "situation_description": "좌현 0.5해리에 횡단 선박 탐지...",
#   "confidence": 0.87
# }
```

*참고: 실제 API URL과 요청/응답 형식은 배포된 모델 및 Prompt Generator 구성에 따라 달라질 수 있다. 배포 화면에 표시되는 요청 JSON 포맷을 참조하여 연동한다.*

## 5.4 테스트 수행

배포 완료 후 "테스트" 탭이 활성화된다. 두 가지 방식으로 테스트를 수행할 수 있다.

### 5.4.1 실시간 질의 입력

테스트 화면에서 질문을 직접 입력하여 모델의 추론 결과를 확인한다. 해양 VLM의 경우 카메라 영상과 AIS 프롬프트를 입력하고, 모델이 항해조력 지시({좌현, 정속} 등)와 해상상황묘사를 올바르게 출력하는지 검증한다.

*[그림 5-3] 실시간 질의 테스트*

### 5.4.2 사전 데이터셋 배치 테스트

우상단의 "사전 데이터셋 선택"으로 전환하면 평가용 데이터셋 전체를 한꺼번에 입력하여 일괄 추론을 수행할 수 있다. 이 방식으로 COLREG 전문가가 평가할 "입력1(이미지) / 입력2(텍스트) / 출력(텍스트) / 평가(오류여부)" 형태의 결과표를 대량 생성한다.

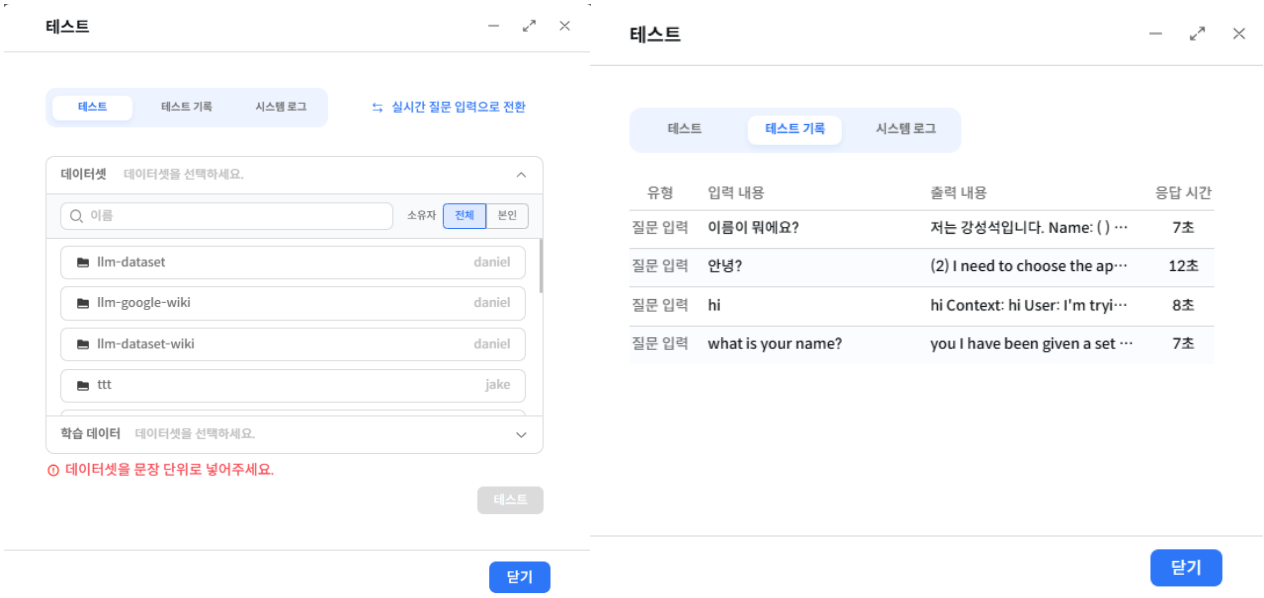


*[그림 5-4] 사전 데이터셋 배치 테스트*

> **참고: 다수의 질의를 일괄 테스트하려면 사전 데이터셋 방식을 활**용하는 것이 효율적이다.

## 5.5 배포 모니터링

"모니터" 탭에서 배포 현황을 실시간으로 확인할 수 있다.

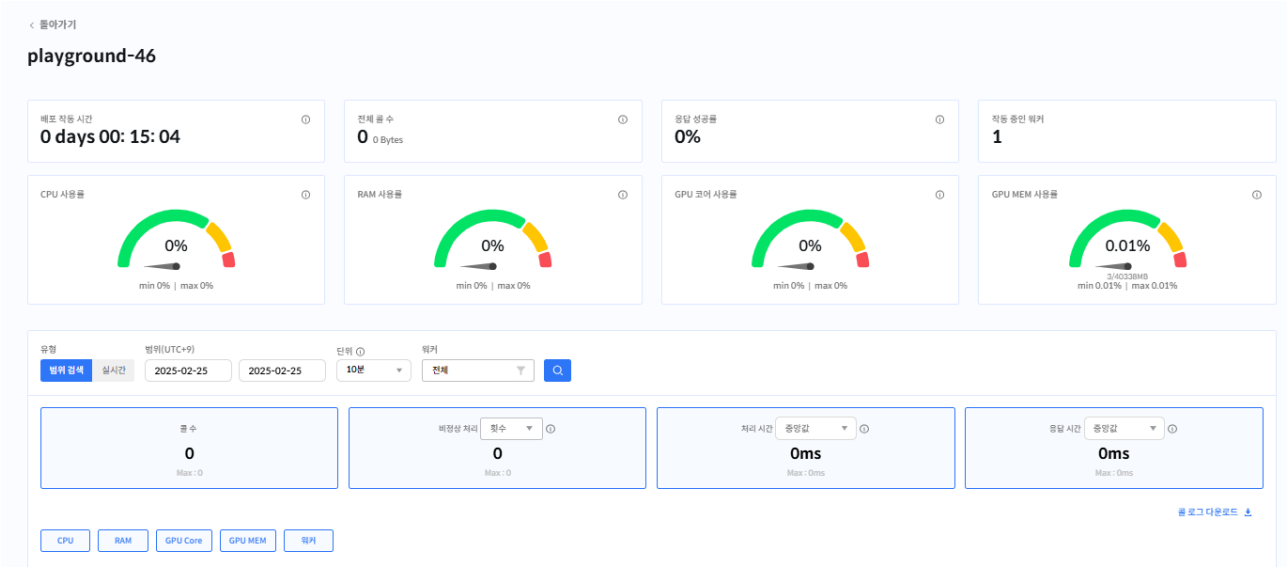


*[그림 5-5a] 배포 모니터링 (상단)*

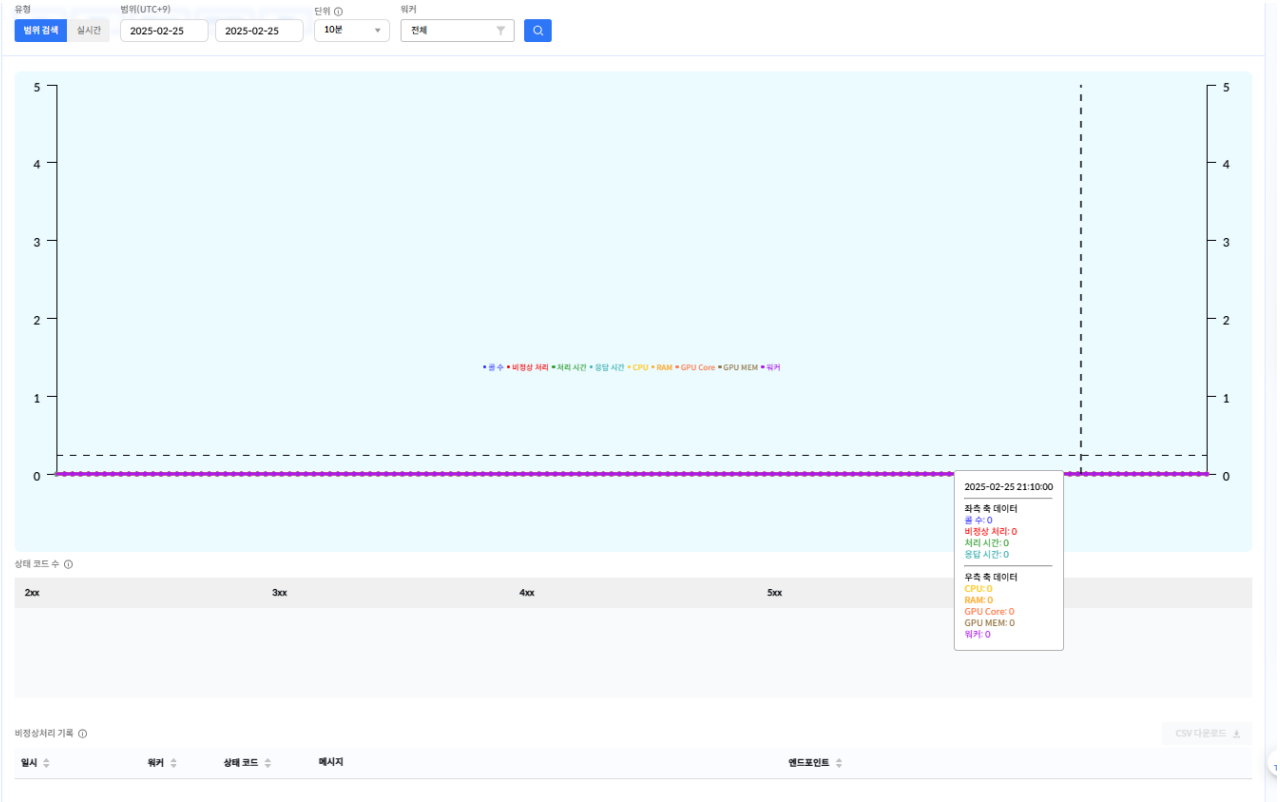


*[그림 5-5b] 배포 모니터링 (하단)*

- 상단: 주요 성능 수치 (각 섹션 우측 상단 인포메이션 아이콘에 마우스 호버 시 설명 제공)
- 하단: 모니터링 데이터 그래프 (필터로 표시 범위 변경 가능)
- 상태 코드 수, 비정상 처리 기록 확인

- 모니터링 로그 다운로드 기능 제공

## 5.6 테스트 기록 및 시스템 로그

"테스트 기록" 탭에서 이전 테스트 이력을 확인할 수 있으며, "시스템로그" 탭에서 각 질문에 대한 상세 시스템 로그를 조회할 수 있다.

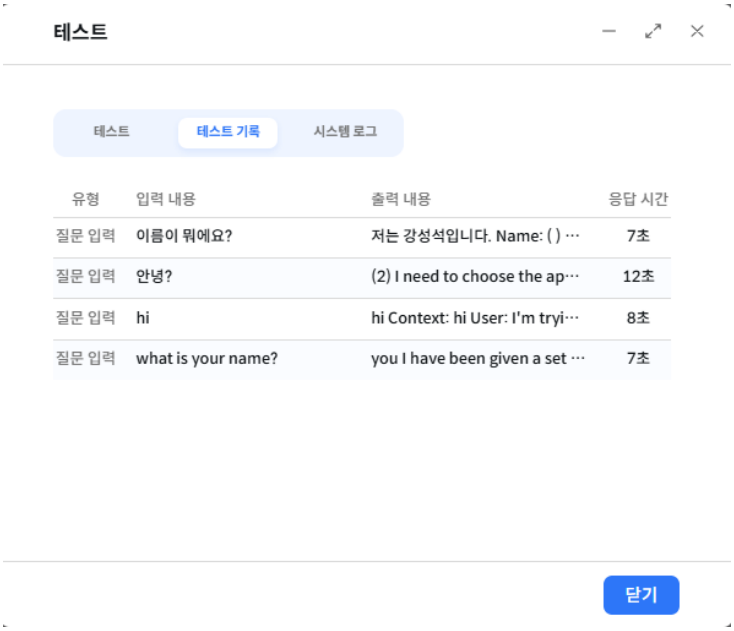


*[그림 5-6] 테스트 기록 및 시스템 로그*

# 6. 평가 및 반복 개선

## 6.1 COLREG 전문가 평가

5장에서 배치 테스트로 생성한 결과표를 COLREG 전문가에게 제공하여, 해당 규칙에 근거한 평가를 수행한다. 평가 기준은 다음과 같다.

| 평가 항목 | 기준 | 목표 |
|---|---|---|
| 항해조력 정확도 | 모델의 방향/속도 지시가 COLREG에 부합하는지 여부 | 오류율 15% 이하 |
| 해상상황묘사 적절성 | 주변 선박 상황을 올바르게 묘사하는지 여부 | 정성적 평가 |

## 6.2 오류 패턴 분석 및 재학습

오류율이 15%를 초과하는 경우, 다음 절차로 반복 개선한다.

- **1 단계 — 오류 패턴 분석:** 테스트 기록에서 오답 사례를 분류하고, 특정 COLREG Rule 에서 오류가 집중되는지 확인
- **2 단계 — 데이터 보강: 오류 빈도가 높은 상황 유형의 데이터를 추가 생성하여 데이터셋에 업로드 (3.2 절 참조)**
- **3 단계 — 재학습: 커밋리스트에서 최적 체크포인트를 선택하여 보강된 데이터로 이어서 파인튜닝 (4.3 절 참조)**
- **4 단계 — 재평가: 플레이그라운드에서 재배포 후 배치 테스트 → 전문가 재평가 (5.3 절 → 5.4.2 절 참조)**

이 루프를 오류율 15% 이하 달성 시까지 반복한다.

# 7. 에이전트 고도화 시나리오

오류율 15% 이하 등의 정량 목표를 달성한 후, VLM 기반 항해조력 모델을 '에이전트'(자율적으로 판단·응답하는 AI 시스템)로 발전시켜 점진적으로 고도화한다. 각 단계에서 Tango2 플랫폼을 활용하는 방법은 다음과 같다.

| 단계 | 구조 | 플랫폼 활용 방법 |
|---|---|---|
| 1단계 | agent → human (음성 출력) | 플레이그라운드에서 배포된 API를 외부 TTS(음성 합성) 모듈과 연결. 모델의 항해조력 텍스트 출력을 TTS가 읽어주는 단방향 시스템 구성. |
| 2단계 | agent ↔ human (대화형 조력) | 동일 배포 API에 대화형 인터페이스 연결. 항해자의 추가 질문("좌측 선박과의 거리는?")에 VLM이 해상상황묘사 기반으로 응답하는 양방향 시스템. |
| 3단계 | agent ↔ agent ↔ human (선박 간 연동) | 복수 선박에 각각 에이전트를 배포. 다중 플레이그라운드 카드를 활용하여 에이전트별 독립 배포/테스트 관리. 에이전트 간 실시간 정보 교환 통해 협력적 항해 조력. |

# 부록 A. 용어집 (Glossary)

본 문서에서 사용하는 주요 용어의 정의이다.

| 용어 | 설명 |
|---|---|
| **VLM (Vision Language Model)** | 이미지와 텍스트를 동시에 입력받아 처리하는 멀티모달 AI 모델. 본 프로젝트에서는 카메라 영상과 AIS 데이터를 기반으로 항해조력 및 해상상황묘사를 생성하는 핵심 모델이다. |
| **COLREG (국제해상충돌예방규칙)** | Convention on the International Regulations for Preventing Collisions at Sea. 해상에서 선박 간 충돌을 방지하기 위한 국제 규칙으로, 본 프로젝트의 평가 기준이 된다. |
| **AIS (선박자동식별장치)** | Automatic Identification System. 선박의 위치(위경도), 속력, 침로, 선수방위 등의 항해 정보를 자동으로 송수신하는 시스템이다. |
| **Prompt Generator** | 카메라 영상과 AIS 센서 데이터를 결합하여 VLM이 이해할 수 있는 구조화된 프롬프트를 자동 생성하는 전처리 모듈이다. |
| **파인튜닝 (Fine-tuning)** | 사전 학습된 대규모 모델을 특정 도메인 데이터로 추가 학습하여, 해당 도메인에 특화된 성능을 끌어내는 기법이다. |
| **LoRA / DoRA** | Low-Rank Adaptation / Weight-Decomposed Low-Rank Adaptation. 모델 전체 파라미터를 동결한 채 소규모 어댑터만 학습하는 PEFT 기법으로, GPU 자원을 절약하면서 효율적으로 파인튜닝할 수 있다. |
| **PEFT (Parameter-Efficient Fine-Tuning)** | 전체 파라미터를 재학습하지 않고 일부 파라미터만 효율적으로 조정하는 파인튜닝 방법론의 총칭이다. |
| **워크스페이스 (Workspace)** | 프로젝트 단위로 구성원, GPU 인스턴스, 스토리지 등의 자원을 묶어 관리하는 Tango2 플랫폼의 논리적 작업 공간이다. |
| **인스턴스 (Instance)** | 워크스페이스에 할당된 GPU 연산 자원의 단위. 학습 및 배포 시 인스턴스 수와 사양에 따라 처리 성능이 결정된다. |
| **커밋 (Commit)** | 파인튜닝 중 특정 시점의 모델 가중치와 학습 설정을 스냅샷으로 저장하는 기능. 이전 커밋으로 돌아가 재학습하거나, 최적 체크포인트를 선택하여 배포할 수 있다. |
| **플레이그라운드 (Playground)** | 학습된 모델을 배포하고 실시간 추론 테스트를 수행할 수 있는 Tango2 플랫폼의 테스트 환경이다. |
| **RESTful API** | 외부 시스템에서 배포된 모델을 HTTP 요청으로 호출하여 추론 결과를 받을 수 있는 표준 통신 인터페이스이다. |
| **SDS 데이터셋** | 해양 상황 데이터셋(Ship Detection & Situation). 카메라 영상, AIS 센서 데이터, 항해조력 라벨 및 해상상황묘사로 구성된 본 프로젝트의 학습용 데이터이다. |
| **배치 테스트 (Batch Test)** | 평가용 데이터셋 전체를 한꺼번에 입력하여 일괄 추론을 수행하는 테스트 방식. 대량의 평가 결과표를 효율적으로 생성할 수 있다. |

# 부록 B. 자주 묻는 질문 (FAQ)

**Q1. 파인튜닝 시작 후 "자원 할당 중" 상태에서 오래 멈춰 있는 경우?**

워크스페이스에 할당된 GPU 인스턴스가 다른 학습/배포 작업에 의해 점유되어 있을 수 있다. 대시보드에서 인스턴스 사용 현황을 확인하고(2.3절 참조), 점유 중인 작업이 완료되기를 대기하거나 워크스페이스 관리자에게 추가 자원 할당을 요청한다.

**Q2. 학습 Loss가 감소하지 않거나 발산하는 경우?**

학습률(Learning Rate)이 너무 높을 가능성이 크다. 학습률을 1/10로 줄여 재시도하고(4.3절 파라미터 설정 참조), LoRA/DoRA 등 PEFT 기법을 적용하여 안정적으로 학습을 진행한다. 데이터셋의 라벨 품질도 함께 검토한다.

**Q3. 배포 완료 후 테스트 탭이 활성화되지 않는 경우?**

배포 상태 표시줄이 "배포 완료"로 변경되었는지 확인한다. 자원 할당 이후 모델 로딩에 추가 시간이 소요될 수 있으며, 상태가 완료로 전환된 후에 테스트 탭이 활성화된다. 문제가 지속되면 브라우저를 새로고침한다.

**Q4. 배치 테스트 결과를 외부로 내보내려면?**

테스트 기록 탭에서 이전 테스트 이력을 확인할 수 있다. 시스템 로그 탭의 데이터를 활용하여 COLREG 전문가 평가용 결과표를 구성한다. 모니터링 로그 다운로드 기능을 통해 상세 데이터를 추출할 수 있다.

**Q5. 커밋 간 성능 차이를 비교하려면?**

플레이그라운드에서 서로 다른 커밋의 모델을 순차적으로 불러와(5.2절 참조) 동일한 평가용 데이터셋으로 배치 테스트를 수행한다(5.4.2절 참조). 각 테스트 기록을 비교하여 최적 체크포인트를 선정한다.

**Q6. 워크스페이스에 접근 권한이 없다는 메시지가 표시되는 경우?**

워크스페이스 관리자에게 사용자 추가를 요청한다. 관리자가 워크스페이스 수정 화면에서 사용자를 초대하면 접근이 가능해진다.